UNIVERSIDAD COMPLUTENSE DE MADRID

ntic master
revolucionamos la comunicación

Módulo: Machine Learning

Autores: Inmaculada Gutiérrez, Daniel Gómez, Juan Antonio Guevara

MACHINE LEARNING

Trabajo de Clasificación binaria

Este trabajo está orientado a predecir una variable **binaria** a través de diferentes algoritmos de clasificación.

Normas para la realización del trabajo

a) El trabajo se hará de forma individual.
b) La entrega del trabajo consta de dos partes.
   i) Memoria del trabajo realizado, entregada en **pdf** a través del Campus Virtual. La tarea se evaluará exclusivamente con el contenido de la memoria, que debe ser **autoexplicativa**, incluyendo fragmentos del código empleado si fuera necesario. **No se admitirán memorias enviadas en formato *.ipynb* o *.py*** o descargadas de Jupyter o cualquier otro editor (con errores, log y similar)**.**
   ii) Código en Python, para poder reproducir los resultados, pero no será evaluado).
c) El trabajo deberá estar **explicado** (no basta con responder a las cuestiones), indicando, si es necesario, el **código utilizado** en el pdf. El trabajo explicado debe ser reproducible, no basta con exponer los resultados. Se valora la claridad de exposición en el informe y la estructura. Puede contener Anexos de datos y gráficos o no, todo según vuestro criterio. Se establece un límite de **20 páginas**.
d) Se debe usar la matriz de datos proporcionada: *BBDD_ML_TAREA.csv*
a) Es importante tener en cuenta que cada técnica exige una depuración/preparación de los datos específicos. No es necesario desarrollar este proceso en cada una de las preguntas, pero es imprescindible explicar para cada técnica qué parte de la depuración/preparación es necesaria.

Enunciado

Una empresa de servicios de telecomunicaciones desea construir un modelo predictivo que permita anticipar la pérdida o abandono de clientes. Para ello dispone de un conjunto de datos con múltiples características de uso y comportamiento de sus clientes, representadas mediante variables independientes *V1–V20*, y una variable dependiente *Y* que codifica si un cliente ha abandonado el servicio o no.

El objetivo principal es desarrollar un sistema de clasificación que determine si un cliente está en riesgo de abandono (*Y* = 1) basándose en sus patrones de consumo y servicio.

El conjunto de datos proporcionado contiene las siguientes variables independientes:

Var	**Detalle**	Var	**Detalle**
V1	Estado/región del cliente	V11	Minutos totales de llamadas vespertinas
V2	Duración de la cuenta con la empresa	V12	Número de llamadas vespertinas
V3	Código de área telefónica	V13	Coste total de llamadas vespertinas
V4	Número de teléfono del cliente	V14	Minutos totales de llamadas nocturnas
V5	Plan internacional contratado (sí/no)	V15	Número de llamadas nocturnas
V6	Plan de buzón de voz contratado (sí/no)	V16	Coste total de llamadas nocturnas
V7	Número de mensajes de buzón de voz	V17	Minutos totales de llamadas internacionales
V8	Minutos totales de llamadas diurnas	V18	Número de llamadas internacionales
V9	Número de llamadas diurnas	V19	Coste total de llamadas internacionales
V10	Coste total de llamadas diurnas	V20	Número de llamadas al servicio de atención

V1–V20 (atributos descriptivos anonimizados de clientes, correspondientes a métricas de uso de servicio, planes contratados, llamadas, cargos y actividad con servicio de atención), y la variable dependiente *Y* (riesgo de abandono).

CUESTIONES A RESPONDER

1) Análisis y depuración de datos

Analiza y depura la base de datos proporcionada, documentando de forma clara y justificada cada una de las transformaciones y técnicas de *feature engineering* aplicadas. Explica por qué cada proceso es necesario y cómo contribuye a mejorar el rendimiento de los modelos de predicción.

2) Regresión logística y red neuronal

- Aplica un proceso de RFE en el que el modelo base sea una regresión logística para seleccionar 5 variables.
- A partir de las variables seleccionadas, diseña y ajusta una red neuronal en términos de Accuracy. Lleva a cabo un proceso detallado de búsqueda paramétrica exhaustiva.
- Justifica de manera detallada:
    - Las parametrizaciones probadas.
    - El threshold de clasificación elegido, en función de la evolución de las métricas durante el entrenamiento.
    - La selección final de parámetros y su impacto en el rendimiento del modelo.

3) Árbol de decisión y red neuronal basada en variables importantes

- Entrena un árbol de decisión y selecciona las variables más relevantes según la importancia calculada por el modelo.
- Utiliza estas variables como entrada para construir y ajustar la mejor red neuronal en términos de Recall. Lleva a cabo un proceso detallado de búsqueda paramétrica exhaustiva.
- Documenta y justifica:
    - Las parametrizaciones probadas (estructura de la red, funciones de activación, número de iteraciones, regularización, etc.).
    - El threshold de clasificación elegido, basándose en la evolución de las métricas durante el entrenamiento.
    - Los parámetros finales seleccionados y su influencia en el resultado obtenido.

4) Comparación global de modelos

Desarrolla un análisis comparativo exhaustivo entre los modelos y procesos seleccionados en los apartados 2) y 3). Compara su rendimiento según las métricas de evaluación empleadas, discute las ventajas e inconvenientes de cada enfoque y argumenta las decisiones metodológicas adoptadas. Concluye con una evaluación crítica de cuál(es) modelo(s) resultan más adecuados para el problema planteado y por qué.